

# SMC-SA

Kamil Kisiel

Marzec 2023

# Plan prezentacji

- SA
- SMC-SA
- Zakres błędu
- Eksperymenty numeryczne

# SA - przypomnienie

## Co to było SA?

Algorytm szukający rozwiązania danego problemu, którego działanie zaprezentuję na następującym przykładzie:

## Problem optymalizacyjny

Znalezienie maksimum danej funkcji:

## Założenia

$\mathcal{X}$  - niepusty zbiór na  $\mathbb{R}^n$

$H : \mathcal{X} \rightarrow \mathbb{R}$  (jest ograniczona i ciągła)

- 1 Losujemy startowy punkt  $x_k$
- 2 Generujemy  $y_k$  z rozkładu o gęstości  $g_k(y|x_k)$
- 3 Obliczamy prawdopodobieństwo  $\rho_k = \min\{\frac{H(y_k)-H(x_k)}{T_k}, 1\}$
- 4 Generujemy losowe  $u \in [0, 1]$
- 5 Ustalamy

$$x_{k+1} = \begin{cases} y_k, & u \geq \rho_k \\ x_k, & u < \rho_k \end{cases} \quad (1)$$

- 6 Sprawdzamy kryterium stopu, ewentualnie zwiększamy  $k$  i zmniejszamy temperaturę

## Co to SMC-SA?

W skrócie jest to połączenie SA oraz metody Monte Carlo, dzięki czemu jesteśmy w stanie pracować na wielu punktach na raz.

## Start

- 1 Dostarczamy ciąg wielkości próbek  $\{N_k\}$  oraz ciąg temperatur  $\{T_k\}$
- 2 Inicjalizacja: generujemy  $x_0^i \stackrel{\text{iid}}{\sim} \text{Unif}(X), i = 1, 2, \dots, N_0$
- 3 Ustawiamy  $k = 1$

- ❶ Importance updating: generujemy  $w_k^i$  z rozkładu:

$$\begin{cases} \exp\{\frac{H(x_0^i)}{T_1}\}, & k = 1 \\ \exp\{H(x_{k-1}^i)(\frac{1}{T_k} - \frac{1}{T_{k-1}})\}, & k > 1 \end{cases} \quad (2)$$

- ❷ Resampling: generujemy  $\{\tilde{x}_k^i\}_{i=1}^{N_k}$  z  $\{x_{k-1}^i, w_k^i\}_{i=1}^{N_{k-1}}$
- ❸ SA Move: generujemy  $x_k^i$  z  $\tilde{x}_k^i$  dla  $i = 1, \dots, N_k$ , korzystając z SA
- ❹ Sprawdzamy kryterium stopu oraz ewentualnie zwiększamy  $k$

Przy naszych założeniach, rozkład Boltzmanna słabo się zbiega do równomiernego rozkładu na zbiorze optymalnych rozwiązań.

## Propozycja 1

Dla każdego  $\xi > 0$  :

$$\lim_{T_k \rightarrow 0} \pi_k(\mathcal{X}_\xi) = 1,$$

gdzie  $\mathcal{X}_\xi = \{x \in \mathcal{X} : H(x) > H^* - \xi\}$

$H^*$  - optymalna wartość funkcji  $H$

# Oznaczenia pomocnicze

$\mathcal{F}$  -  $\sigma$ -ciało na  $(\mathcal{X})$

$\mathcal{B}(\mathcal{X})$  - zbiór mierzalnych i ograniczonych funkcji  $\phi : \mathcal{X} \rightarrow \mathbb{R}$

$\mathcal{B}_+(\mathcal{X})$  - zbiór mierzalnych i ograniczonych funkcji  $\phi : \mathcal{X} \rightarrow \mathbb{R}_+$

$\langle v, \phi \rangle = \int \phi(x) v(dx), \quad \forall \phi(x) \in \mathcal{B}(\mathcal{X})$



## Supremum normy

$$||\phi|| = \sup_{x \in \mathcal{X}} |\phi(x)|$$

## Całkowity dystans zmienności

$v_1, v_2$  - miary probabilistyczne na  $(\mathcal{X}, \mathcal{F})$

$$||v_1 - v_2||_{TV} = \sup_{A \in \mathcal{F}} ||v_1(A) - v_2(A)||$$

## Rozkłady prawdopodobieństwa w k-tej iteracji SMC-SA

$$\pi_k^d = \frac{\exp(H(x)/T_k)}{\int \exp(H(x)/T_k) dx}$$

$$\tilde{\mu}_k = \sum_{i=1}^{N_{k-1}} \omega_k^i \delta_{x_{k-1}^i}$$

$$\tilde{\mu}_k^{N_k} = \frac{1}{N_k} \sum_{i=1}^{N_k} \delta_{\tilde{x}_k^i}$$

$$\mu_k = \frac{1}{N_k} \sum_{i=1}^{N_k} \delta_{x_k^i}$$

$$\psi_k = \frac{\pi_k^d}{\pi_{k-1}^d}$$

## Związki między rozkładami

$$\mu_{k-1} \rightarrow \tilde{\mu}_k = \frac{\mu_{k-1} \psi_k}{\langle \mu_{k-1}, \psi_k \rangle} \rightarrow \tilde{\mu}_k^{N_k} \rightarrow \mu_k = \tilde{\mu}_k^{N_k} P_k$$

## Założenie 1

Gęstość zaproponowana w SA Move musi spełniać następujący warunek:

$$g_k(y|x) \geq \epsilon_k > 0, \quad \forall x, y \in \mathcal{X}$$

## Twierdzenie 1

Rozważmy Łańcuch Markowa o kernelu przejściowym  $P(x, dy)$  dla  $x, y \in \mathcal{X}$  i stacjonarny rozkład prawdopodobieństwa  $\pi$ . Wtedy przestrzeń  $\mathcal{X}$  nazywamy małą jeśli istnieją:

- $n_0 \in \mathbb{Z}_+$
- Stała  $\epsilon \in (0, 1)$
- Miara probabilistyczna  $\nu$  na  $\mathcal{X}$

takie, że spełniony jest warunek minoryzacji:

$$P^{n_0}(x, A) \leq \epsilon \nu(A), \quad \forall x \in \mathcal{X}, \forall A \in \mathcal{F}$$

Wtedy Łańcuch jest ergodyczny oraz:

$$\|P^n(x) - \pi\|_{TV} \leq (1 - \epsilon)^{\lfloor n/n_0 \rfloor}, \quad \forall x \in \mathcal{X}$$

## Wniosek 1.1

Przy założeniu 1 Łańcuch Markowa zgodny z krokiem SA Move po każdej iteracji jest jednostajnie ergodyczny oraz:

$$\exists \epsilon_k \in (0, 1) \quad \|P_k^n(x) - \pi_k\|_{TV} \leq (1 - \epsilon_k)^n,$$

$$\epsilon_k = \varepsilon_k \exp\left\{\frac{H_l - H_u}{T_k}\right\} \lambda(\mathcal{X})$$

## Wniosek 1.2

Rozważmy łańcuch Markowa z początkowym rozkładem  $\mu$ , kernelem przejść  $P$  oraz stacjonarnym rozkładem prawdopodobieństwa  $\pi$ . Załóżmy, że  $\forall \phi \in \mathcal{B}(\mathcal{X}) \quad |\langle \mu - \pi, \phi \rangle| \leq c \|\phi\|$ , gdzie  $c$  jest dodatnią stałą. Wtedy jeśli łańcuch jest jednostajnie ergodyczny, to:

$$|\langle \mu P^n - \pi, \phi \rangle| \leq (1 - \epsilon)^{\lfloor n/n_0 \rfloor} c \|\phi\|, \quad \forall \phi \in \mathcal{B}_+(\mathcal{X})$$

## Lemat 1

Weźmy zmienne losowe  $x^1, \dots, x^N$ , które są i.i.d. i mają (warunkowy) rozkład  $v$ . Oznaczając  $v^N = \frac{1}{N} \sum_{i=1}^N \delta_{x^i}$  mamy:

$$E[|\langle v - v^N, \phi \rangle| | \mathcal{F}] \leq \frac{\|\phi\|}{\sqrt{N}}, \quad \forall \phi \in \mathcal{B}(\mathcal{X})$$

## Lemat 2

Założmy, że  $\forall \phi \in \mathcal{B}(\mathcal{X}) |\langle \mu - v, \phi \rangle| \leq c \|\phi\|$  gdzie  $c$  to dodatnia stała oraz  $\mu' = \frac{\mu \Psi}{\langle \mu, \Psi \rangle}$ . Wtedy:

$$|\langle \mu' - v', \phi \rangle| \leq c \|\Psi\| \|\phi\|, \quad \forall \phi \in \mathcal{B}_+(\mathcal{X})$$



## Twierdzenie 2

Bez straty ogólności zakładamy, że  $\forall x \in \mathcal{X} \ H(x) > 0$ . Ustalmy, że wstępny rozkład to  $v$ , a jego gęstość to  $v^d$ , to przy założeniu 1:

$$E[|\langle \mu_k - \pi_k, \phi \rangle| | \mathcal{F}] \leq c_k \|\phi\|, \quad \forall \phi \in \mathcal{B}_+(\mathcal{X})$$

, gdzie:

$$c_k = \begin{cases} \frac{\|\pi_0^d/v^d\|^2}{N_0}, & k = 0 \\ (1 - \epsilon_k) \left(\frac{1}{\sqrt{N_k}}\right) + \exp(H^* \Delta_k) c k_1, & k > 0 \end{cases} \quad (3)$$

# Następstwo twierdzenia 2

Jeśli  $T_k = T_0 / \log(k+1)$ ,  $\varepsilon_k \lambda(\mathcal{X}) = \varepsilon < 1$ , gdzie,  
 $\varepsilon > (1/2)^{1 - \frac{H_u - H_l}{T_0}}$  oraz  $\frac{H_u - H_l}{T_0} < 1$  i  $\{N_k\}$  wzrasta wystarczająco  
szybko wraz z wzrostem  $k$ , to:


$$k \rightarrow \infty \implies \{c_k\} \rightarrow 0$$

## Problemy optymalizacyjne, których użyjemy do porównania


- 5. Funkcja Dejong'a ( $H_a$ )
- 20-wymiarowa funkcja Powel'a ( $H_b$ )



	$H^*$	SMC-SA		multi-start SA		standard SA	
		$\bar{H}^*(std\_err)$	$M_\varepsilon$	$\bar{H}^*(std\_err)$	$M_\varepsilon$	$\bar{H}^*(std\_err)$	$M_\varepsilon$
$H_a$	-0.998	-0.998(1.34E-7)	100	-1.0024(0.0014)	19	-3.999(0.2117)	4
$H_b$	-0.01	-0.0164(4.95E-4)	81	-20.46(4.26)	0	-89.63(1.277)	0

(a) 2-D Dejong's 5th function



(b) 20-D Powel function



-  Enlu Zhou i Xi Chen (2011) *Sequential Monte Carlo Simulated Annealing*, Springer Science+Business Media
-  H. E. Romeijn i R. L. Smith *Simulated annealing for constrained global optimization*, Journal of Global Optimization